







# Байесовские методы. Лекция 4. Байесовский вывод для линейной регрессии.

Целищев М.А.

МГУ им. М. В. Ломоносова  
Факультет вычислительной математики и кибернетики  
Кафедра математической статистики

весна 2021

## Список литературы

-  J. Kruschke. Doing Bayesian Data Analysis, Second Edition. A Tutorial with R, JAGS, and Stan. Academic Press, 2014.
-  R. McElreath. Statistical Rethinking. A Bayesian Course with Examples in R and Stan. Chapman and Hall CRC, 2015.
-  O. Martin. Bayesian Analysis with Python. Introduction to Statistical Modeling and Probabilistic Programming using PyMC3 and ArviZ, Second Edition. Packt, 2018.
-  K. P. Murphy. Machine Learning: A Probabilistic Perspective. The MIT Press, 2012.
-  A. Gelman, J. Carlin, H. Stern, D. Dunson, A. Vehtari, D. Rubin. Bayesian Data Analysis, Third Edition. CRC Press, 2013.
-  S. Brooks, A. Gelman, G. L. Jones and X.-L. Meng. Handbook of Markov Chain Monte Carlo. Chapman & Hall/CRC, 2011.

## Задача регрессии

По вектору признаков  $\mathbf{x} = (x_1, \dots, x_d) \in \mathbb{R}^d$  хотят предсказать значение целевой переменной  $t \in \mathbb{R}$ .

Пример: предсказание изменения цены на нефть за день (в процентах). Признаками могут быть изменение цены нефти или других товаров/ценных бумаг за прошлые периоды, текущие процентные ставки и пр.

В наличии исследователя имеется тренировочная выборка

$$D_{\text{tr}} = \{(t_i, \mathbf{x}_i)\}_{i=1}^n, \quad t_i \in \mathbb{R}, \quad \mathbf{x}_i \in \mathbb{R}^d,$$

то есть конечный набор пар (целевая переменная, вектор признаков). В примере с ценой нефти это могут быть уже известные к текущему моменту наблюдения.

Требуется подобрать алгоритм, который по новому вектору признаков будет делать прогноз на целевую переменную.

## Линейная регрессия

Обозначим  $\mathbf{t} = (t_1, \dots, t_n)^T \in \mathbb{R}^n$  — вектор целевых переменных,  
 $\mathbf{X} = (x_{ij}) \in \mathbb{R}^{n \times d}$  — матрица признаков (строка  $\mathbf{x}_i = (x_{i1}, \dots, x_{id})$  которой соответствует целевой переменной  $t_i$ ).

Тогда с точки зрения линейной модели,

$$t_i \approx w_0 + \sum_{j=1}^d w_j x_{ij}, \quad i = 1 \dots n,$$

где  $\mathbf{w} = (w_0, w_1, \dots, w_d)$  — вектор параметров (весов), который нужно подобрать по тренировочной выборке.


Здесь важно, что целевая переменная *линейно* зависит от *вектора параметров*  $\mathbf{w}$ , поэтому такая модель и называется *линейной*.

Понятно, что поскольку обычно  $n \gg d$ , то надеяться на точное равенство не приходится.

## Линейная регрессия

Иными словами, хотят провести гиперплоскость в пространстве  $\mathbb{R}^{d+1}$ , которая бы «наилучшим образом» описывала зависимость между целевой переменной и признаками.

На графике ниже представлен случай  $d = 1$ .



## Линейная регрессия

Для удобства можно считать, что первый признак есть всегда константа 1, то есть  $x_{i1} = 1, i = 1 \dots n$ . В таком случае не нужен  $w_0$  и постановка задачи запишется в виде

$$\mathbf{t} \approx \mathbf{X}\mathbf{w}, \quad \mathbf{t} \in \mathbb{R}^n, \mathbf{X} \in \mathbb{R}^{n \times d},$$

и обычно ищут такой вектор весов  $\mathbf{w}^* \in \mathbb{R}^d$ , который минимизировал бы сумму квадратов ошибок:

$$\mathbf{w}^* = \arg \min_{\mathbf{w} \in \mathbb{R}^d} \sum_{i=1}^n \left( t_i - \sum_{j=1}^d w_j x_{ij} \right)^2 = \arg \min_{\mathbf{w} \in \mathbb{R}^d} \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2$$

Такой инженерный подход называют *методом наименьших квадратов* (МНК).

Как найти оптимальные веса  $\mathbf{w}^*$ ?

$$\mathbf{w}^* = \arg \min_{\mathbf{w} \in \mathbb{R}^d} \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2 = \arg \min_{\mathbf{w} \in \mathbb{R}^d} Q(\mathbf{w}),$$

где

$$Q(\mathbf{w}) = \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2 = (\mathbf{t} - \mathbf{X}\mathbf{w})^T (\mathbf{t} - \mathbf{X}\mathbf{w}) = \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{w}^T \mathbf{X}^T \mathbf{t} + \mathbf{t}^T \mathbf{t}.$$

Градиентом числовой функции  $Q$  векторного аргумента  $\mathbf{w}$  называют вектор частных производных:  $\nabla Q(\mathbf{w}) = \left( \frac{\partial Q}{\partial w_1}(\mathbf{w}), \dots, \frac{\partial Q}{\partial w_d}(\mathbf{w}) \right)$ .

Поскольку  $Q(\mathbf{w})$  — выпуклая функция, то точка её минимума будет совпадать с точкой, в которой градиент равен нулю.

$$\begin{aligned} \frac{\partial Q}{\partial w_j} &= \frac{\partial}{\partial w_j} (\mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w}) - 2 \frac{\partial}{\partial w_j} (\mathbf{w}^T \mathbf{X}^T \mathbf{t}) = \\ &= \frac{\partial}{\partial w_j} \left( \sum_{k,m=1}^d w_k (\mathbf{X}^T \mathbf{X})_{km} w_m \right) - 2 \frac{\partial}{\partial w_j} \left( \sum_{k=1}^d w_k (\mathbf{X}^T \mathbf{t})_k \right) = \\ &= 2(\mathbf{X}^T \mathbf{X})_{jj} w_j + 2 \left( \sum_{k \neq j} (\mathbf{X}^T \mathbf{X})_{jk} w_k \right) - 2(\mathbf{X}^T \mathbf{t})_j. \end{aligned}$$

## Линейная регрессия

Итак,

$$\frac{\partial Q}{\partial w_j} = 2 \left( \sum_{k=1}^d (\mathbf{X}^T \mathbf{X})_{jk} w_k \right) - 2 (\mathbf{X}^T \mathbf{t})_j.$$

Иными словами,

$$\nabla Q(\mathbf{w}) = 2\mathbf{X}^T \mathbf{X} \mathbf{w} - 2\mathbf{X}^T \mathbf{t},$$

и точкой нулевого градиента будет

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{t}$$

(при условии, что матрица  $\mathbf{X}^T \mathbf{X} \in \mathbb{R}^{d \times d}$  обратима).

Матрица  $(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \in \mathbb{R}^{d \times n}$  называется *псевдообратной* к прямоугольной матрице  $\mathbf{X} \in \mathbb{R}^{n \times d}$ , и является обобщением понятия обратной для квадратной матрицы.



## Линейная регрессия, регуляризация

Что делать, если матрица  $\mathbf{X}^T \mathbf{X} \in \mathbb{R}^{d \times d}$  необратима? Так будет, если у матрицы  $\mathbf{X}^T \mathbf{X}$  есть нулевые собственные значения, что свидетельствует о линейной зависимости столбцов матрицы  $\mathbf{X}$ .

В таком случае ищут решение регуляризованной задачи:

$$\mathbf{w}_\lambda^* = \arg \min_{\mathbf{w} \in \mathbb{R}^d} \left( \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2 + \lambda \|\mathbf{w}\|^2 \right) = \arg \min_{\mathbf{w} \in \mathbb{R}^d} Q(\mathbf{w}, \lambda)$$

для некоторого  $\lambda > 0$ , где  $Q(\mathbf{w}, \lambda) = Q(\mathbf{w}) + \lambda \|\mathbf{w}\|^2$ .

Иными словами, накладывается штраф на слишком большие по модулю веса. При этом

$$\nabla_{\mathbf{w}} Q(\mathbf{w}, \lambda) = \nabla_{\mathbf{w}} Q(\mathbf{w}) + 2\lambda \mathbf{w} = 2(\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I}) \mathbf{w} - 2\mathbf{X}^T \mathbf{t},$$

где  $\mathbf{I} = \text{diag}(1, \dots, 1)$  — единичная матрица размера  $d \times d$ .

Итак, решением регуляризованной задачи будет вектор весов

$$\mathbf{w}_\lambda^* = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{t},$$

## Линейная регрессия, вероятностный подход

А как решают эту же задачу в статистике?

Полагают, что все наблюдения  $t_i$  над целевой переменной независимы и имеют нормальное распределение  $\mathcal{N}(\mathbf{x}_i^T \mathbf{w}, \sigma^2)$  с некоторой (неизвестной) дисперсией  $\sigma^2$  и вектором параметров  $\mathbf{w} \in \mathbb{R}^d$ . Иными словами, вероятностная модель будет иметь вид

$$\mathbf{t} \sim \mathcal{N}(\mathbf{X}\mathbf{w}, \sigma^2 \mathbf{I}),$$

или, что равносильно,

$$\mathbf{t} = \mathbf{X}\mathbf{w} + \varepsilon, \quad \varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}),$$

где  $\varepsilon$  — шум в наблюдениях, подчиняющийся нормальному закону с нулевым средним и дисперсией  $\sigma^2$ .

Как оценивают неизвестные параметры в статистике?

## Линейная регрессия, вероятностный подход

Как всегда, методом максимального правдоподобия!

$$\mathbf{t} \sim \mathcal{N}(\mathbf{X}\mathbf{w}, \sigma^2 \mathbf{I}),$$

Функция правдоподобия для такой модели есть:

$$\mathcal{L}(\mathbf{t}; \mathbf{w}, \sigma) = \frac{1}{(2\pi\sigma^2)^{n/2}} \cdot \exp\left(-\frac{1}{2\sigma^2}(\mathbf{t} - \mathbf{X}\mathbf{w})^T(\mathbf{t} - \mathbf{X}\mathbf{w})\right).$$

Тогда  $\arg \max_{\mathbf{w}, \sigma} \mathcal{L}(\mathbf{t}; \mathbf{w}, \sigma) = \arg \max_{\mathbf{w}, \sigma} \ln L(\mathbf{t}; \mathbf{w}, \sigma)$  и

$$\max_{\mathbf{w}, \sigma} \ln \mathcal{L}(\mathbf{t}; \mathbf{w}, \sigma) = \min_{\mathbf{w}, \sigma} \left( \frac{n}{2} \ln(2\pi\sigma^2) + \frac{1}{2\sigma^2} \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2 \right).$$

Отсюда следует, что максимизаторами правдоподобия будут:

$$\mathbf{w}_{\text{ML}} = \arg \min_{\mathbf{w} \in \mathbb{R}^d} \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2 = \mathbf{w}^*, \quad \sigma_{\text{ML}}^2 = \frac{1}{n} \|\mathbf{t} - \mathbf{X}\mathbf{w}_{\text{ML}}\|^2,$$

т. е. задача максимизации правдоподобия для такой модели эквивалентна МНК.

А как в таком подходе прикрутить регуляризацию???

## Линейная регрессия, байесовский подход

Очень просто, нужно провести байесовский вывод!

При этом правдоподобие, как и ранее:

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \sigma) \equiv \mathcal{L}(\mathbf{t}; \mathbf{w}, \sigma) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2\right),$$

то есть

$$(\mathbf{t}|\mathbf{X}, \mathbf{w}, \sigma) \sim \mathcal{N}(\mathbf{X}\mathbf{w}, \sigma^2\mathbf{I}).$$

Стандартный вопрос в байесовском выводе: какое брать априорное распределение для  $\mathbf{w}$ ?

$$p(\mathbf{w}) = p(\mathbf{w}|\mathbf{X}, \sigma) = ???$$

Как водится, надо постараться взять такой класс априорных, чтобы соответствующее апостериорное снова оказалось бы в этом классе (напомним, что такие классы называются *сопряжёнными* к заданному правдоподобию).

## Линейная регрессия, байесовский подход

Итак, правдоподобие:  $\mathbf{t}|\mathbf{X}, \mathbf{w}, \sigma \sim \mathcal{N}(\mathbf{X}\mathbf{w}, \sigma^2\mathbf{I})$ , или

$$p(\mathbf{t}|\mathbf{X}, \mathbf{w}, \sigma) \propto \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2\right)$$

Функционально это квадратичная функция по  $\mathbf{w}$  «со знаком минус» под экспонентой. Поэтому в качестве априорного распределения следует брать:

$$\mathbf{w} \sim \mathcal{N}(\mu_0, \Sigma_0), \quad \mu_0 \in \mathbb{R}^d, \quad \Sigma_0 \in \mathbb{R}^{d \times d},$$

то есть  $p(\mathbf{w}) \propto \exp\left(-\frac{1}{2}(\mathbf{w} - \mu_0)^T \Sigma_0^{-1}(\mathbf{w} - \mu_0)\right)$ ,  $\mathbf{w} \in \mathbb{R}^d$ .

Тогда по теореме Байеса, апостериорное распределение  $\mathbf{w}$  будет иметь вид:

$$p(\mathbf{w}|\mathbf{t}, \mathbf{X}, \sigma) = \frac{p(\mathbf{w}|\mathbf{X}, \sigma) p(\mathbf{t}|\mathbf{w}, \mathbf{X}, \sigma)}{p(\mathbf{t}|\mathbf{X}, \sigma)} = \frac{p(\mathbf{w}) p(\mathbf{t}|\mathbf{w}, \mathbf{X}, \sigma)}{p(\mathbf{t}|\mathbf{X}, \sigma)}.$$

Осталось только посчитать, чему это равно...

## Линейная регрессия, байесовский подход

$$\begin{aligned} p(\mathbf{w}|\mathbf{t}, \mathbf{X}, \sigma) &\propto \exp\left(-\frac{1}{2}(\mathbf{w} - \mu_0)^T \Sigma_0^{-1}(\mathbf{w} - \mu_0)\right) \cdot \exp\left(-\frac{1}{2\sigma^2}\|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2\right) \propto \\ &\propto \exp\left(-\frac{1}{2}\left[\mathbf{w}^T \Sigma_0^{-1} \mathbf{w} - 2\mu_0^T \Sigma_0^{-1} \mathbf{w} + \frac{1}{\sigma^2} \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - \frac{2}{\sigma^2} \mathbf{t}^T \mathbf{X} \mathbf{w}\right]\right) \propto \\ &\propto \exp\left(-\frac{1}{2}\left[\mathbf{w}^T \left(\Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{X}\right) \mathbf{w} - 2\left(\mu_0^T \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{t}^T \mathbf{X}\right) \mathbf{w}\right]\right) \end{aligned}$$

Напомним теперь, как выглядит плотность нормального распределения  $\mathbf{z} \sim \mathcal{N}(\mu, \Sigma)$  в  $\mathbb{R}^d$ :

$$p(\mathbf{z}) \propto \exp\left(-\frac{1}{2}(\mathbf{z} - \mu)^T \Sigma^{-1}(\mathbf{z} - \mu)\right) \propto \exp\left(-\frac{1}{2}\left[\mathbf{z}^T \Sigma^{-1} \mathbf{z} - 2\mu^T \Sigma^{-1} \mathbf{z}\right]\right).$$

## Линейная регрессия, байесовский подход

Из сказанного выше делаем вывод, что апостериорное распределение  $\mathbf{w}$  имеет вид:

$$\mathbf{w}|\mathbf{t}, \mathbf{X}, \sigma \sim \mathcal{N}(\mu_n, \Sigma_n),$$

где

$$\Sigma_n = \left( \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{X} \right)^{-1}$$

и

$$\mu_n^T \Sigma_n^{-1} = \mu_0^T \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{t}^T \mathbf{X},$$

то есть

$$\mu_n^T = \left( \mu_0^T \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{t}^T \mathbf{X} \right) \cdot \Sigma_n,$$

или

$$\mu_n = \Sigma_n \left( \Sigma_0^{-1} \mu_0 + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{t} \right) = \left( \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \left( \Sigma_0^{-1} \mu_0 + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{t} \right).$$

## Линейная регрессия, байесовский подход

$$(\mathbf{w}|\mathbf{t}, \mathbf{X}, \sigma) \sim \mathcal{N}(\mu_n, \Sigma_n)$$

Поскольку максимум плотности нормального распределения достигается в его центре, то оценкой максимума плотности апостериорного распределения (МАР-оценкой) будет апостериорное среднее  $\mu_n$ :

$$\mathbf{w}_{\text{МАР}} = \arg \max_{\mathbf{w} \in \mathbb{R}^d} p(\mathbf{w}|\mathbf{t}, \mathbf{X}, \sigma) = \mu_n = \left( \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \left( \Sigma_0^{-1} \mu_0 + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{t} \right).$$

Если бы в качестве априорных параметров  $\mu_0$  и  $\Sigma_0$  взяли бы

$$\mu_0 = \mathbf{0} \in \mathbb{R}^d, \quad \Sigma_0 = \alpha \mathbf{I} \in \mathbb{R}^{d \times d},$$

то получили бы

$$\mathbf{w}_{\text{МАР}} = \left( \frac{1}{\alpha} \mathbf{I} + \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{X} \right)^{-1} \left( \frac{1}{\sigma^2} \mathbf{X}^T \mathbf{t} \right) = \left( \mathbf{X}^T \mathbf{X} + \lambda \mathbf{I} \right)^{-1} \mathbf{X}^T \mathbf{t},$$

где  $\lambda = \frac{\sigma^2}{\alpha}$ . То есть метод наименьших квадратов с регуляризацией есть частный случай байесовского вывода (поиск МАР-оценки для линейной нормальной модели со специальными  $\mu_0$  и  $\Sigma_0$ ).



## Линейная регрессия, байесовский подход

Разобранный подход носит название Ridge-регрессии.

А если бы в качестве априорного взяли *распределение Лапласа*, то есть

$$p(\mathbf{w}) \propto \exp\left(-\alpha \sum_{j=1}^d |w_j|\right), \quad \alpha > 0,$$

и решали бы задачу поиска MAP-оценки для  $\mathbf{w}$ , то снова бы получили

$$\mathbf{w}_{\text{MAP}} = \arg \min_{\mathbf{w}} \left( \|\mathbf{t} - \mathbf{X}\mathbf{w}\|^2 + \lambda \sum_{j=1}^d |w_j| \right),$$

но уже с  $L_1$ -регуляризатором. Это LASSO-регрессия.

Но байесовский вывод лучше ещё и потому, что позволяет найти не только точечную оценку параметров  $\mathbf{w}$ , но *целое апостериорное распределение* для них!

Это позволяет оценить степень уверенности или неуверенности в конкретных значениях параметров, строить доверительные интервалы для них, проверять гипотезы и пр.

## Линейная регрессия, предсказания

Теперь необходимо сделать предсказание целевой переменной  $t_{\text{new}} \in \mathbb{R}$  для нового вектора признаков  $\mathbf{x}_{\text{new}} \in \mathbb{R}^d$ , имея в наличии тренировочную выборку  $D_{\text{tr}} = \{\mathbf{t}, \mathbf{X}\}$ .

Классическая статистика даёт такое предсказание на целевую переменную:

$$t_{\text{new}} \sim \mathcal{N}(\mathbf{x}_{\text{new}}^T \mathbf{w}_{\text{ML}}, \sigma_{\text{ML}}^2).$$

А байесовская? Как обычно, надо усреднить правдоподобие нового наблюдения по апостериорному распределению параметров:

$$p(t_{\text{new}} | \mathbf{x}_{\text{new}}, D_{\text{tr}}, \sigma) = \int_{\mathbb{R}^d} p(t_{\text{new}} | \mathbf{x}_{\text{new}}, \mathbf{w}, \sigma) p(\mathbf{w} | D_{\text{tr}}, \sigma) d\mathbf{w},$$

где  $(t_{\text{new}} | \mathbf{x}_{\text{new}}, \mathbf{w}, \sigma) \sim \mathcal{N}(\mathbf{x}_{\text{new}}^T \mathbf{w}, \sigma^2)$  и  $(\mathbf{w} | D_{\text{tr}}, \sigma) \sim \mathcal{N}(\mathbf{w}_{\text{MAP}}, \Sigma_n)$ .

**ДЗ (\*):** показать, что

$$(t_{\text{new}} | \mathbf{x}_{\text{new}}, D_{\text{tr}}, \sigma) \sim \mathcal{N}(\mathbf{x}_{\text{new}}^T \mathbf{w}_{\text{MAP}}, \sigma^2 + \mathbf{x}_{\text{new}}^T \Sigma_n \mathbf{x}_{\text{new}}).$$

## Априорное распределение и для $\sigma$

В байесовском выводе выше считалось, что шум наблюдений  $\sigma$  известен, но по-байесовски следовало бы навесить априорное распределение и на него.

Если взять априорным

$$\begin{aligned}\sigma^2 &\sim \text{InvGamma}(a_0, b_0), \\ \mathbf{w}|\sigma^2 &\sim \mathcal{N}(\mu_0, \sigma^2 \Sigma_0),\end{aligned}$$

то апостериорным тоже окажется гамма-нормальное распределение:

$$\begin{aligned}\sigma^2|\mathbf{t}, \mathbf{X} &\sim \text{InvGamma}(a_n, b_n), \\ \mathbf{w}|\mathbf{t}, \mathbf{X}, \sigma^2 &\sim \mathcal{N}(\mu_n, \sigma^2 \Sigma_n),\end{aligned}$$

где  $a_n = a_0 + n/2$ ,  $b_n = b_0 + \frac{1}{2} (\mu_0^T \Sigma_0^{-1} \mu_0 + \mathbf{t}^T \mathbf{t} - \mu_n^T \Sigma_n^{-1} \mu_n)$ ,

$$\mu_n = \Sigma_n (\Sigma_0^{-1} \mu_0 + \mathbf{X}^T \mathbf{t}), \quad \Sigma_n = (\Sigma_0^{-1} + \mathbf{X}^T \mathbf{X})^{-1}.$$